



RESUMO DA VIDEOAULA - AULA 01

IA

Projeto: Avaliação de Risco de Crédito

Professor: Rogério Andrade

Duração: 2h26min | Plataforma: Google Colab (Jupyter Notebook)



Visão Geral

Esta aula inaugural da disciplina de Inteligência Artificial apresenta o projeto prático "Avaliação de Risco de Crédito", utilizado como caso de estudo ao longo do curso. O professor Rogério conduz os alunos por todo o fluxo de um projeto de ciência de dados e Machine Learning, desde a análise exploratória dos dados até a construção e comparação de modelos preditivos. O objetivo principal é construir um modelo capaz de prever se um cliente de uma fintech (No Bank) será inadimplente ou adimplente no pagamento do cartão de crédito, utilizando dados históricos dos clientes.



Tópicos Abordados

Tópico 1: Introdução e contextualização — O dado como novo petróleo e o fluxo do projeto de IA

Tópico 2: Contextualização do problema — Avaliação de risco de crédito na fintech No Bank

Tópico 3: Tipos de aprendizado de máquina — Supervisionado vs. Não supervisionado; Classificação vs. Regressão

Tópico 4: Análise exploratória dos dados (EDA) — Dimensões, tipos de variáveis, dados faltantes

Tópico 5: Análise descritiva — Estatísticas, média, desvio padrão, quartis

Tópico 6: Tratamento de dados faltantes — Estratégias de imputação e exclusão

Tópico 7: Análise de outliers — Conceito, identificação e tratamento

Tópico 8: Análise de correlação — Conceito, correlação vs. causalidade, mapa de calor

Tópico 9: Balanceamento de classes — Dados desbalanceados, técnicas de undersample e oversample

Tópico 10: Limpeza e preparação dos dados — Exclusão de variáveis irrelevantes, tratamento de valores nulos

Tópico 11: Padronização (StandardScaler) — Colocar variáveis na mesma escala

Tópico 12: Construção e comparação de modelos — Árvore de Decisão, Random Forest, XGBoost, KNN, Regressão Logística



Explicação Detalhada

Tópico 1: Introdução e contextualização

O que foi abordado: O professor introduziu a aula explicando que o objetivo é trabalhar o conceito de análise exploratória de dados e mostrar o fluxo completo de um projeto de IA, desde a coleta dos dados até a construção do modelo.

Como o professor explicou: Utilizou a analogia do "dado como o novo petróleo", explicando que assim como o petróleo, o dado não tem valor se não for tratado. Enfatizou que o primeiro passo é montar boas técnicas de coleta, criar um datalake e estruturar os dados.

Exemplos utilizados: Comparação entre dado bruto e petróleo bruto — ambos precisam de refino/tratamento para gerar valor. Mencionou que bancos e fintechs utilizam modelos de Machine Learning para prevenir inadimplência.

Observações importantes: O professor ressaltou que a maior parte do trabalho de um cientista de dados (cerca de 80%) é dedicada à preparação e limpeza dos dados, e apenas 20% ao modelo em si.

Tópico 2: Contextualização do problema

O que foi abordado: Apresentação do caso de estudo: prever a probabilidade de um cliente da startup "No Bank" não cumprir suas obrigações financeiras (deixar de pagar a fatura do cartão de crédito).

Como o professor explicou: Mostrou o notebook Jupyter (Google Colab) com o projeto "Avaliação de Risco de Crédito", lendo e comentando a descrição do problema. Explicou que o dataset contém dados de clientes com informações sobre perfil, renda, tipo de trabalho, estado civil, entre outros.

Exemplos utilizados: Comparou com o contexto de instituições financeiras tradicionais e fintechs que precisam tomar decisões inteligentes sobre empréstimos baseadas em dados.

Observações importantes: O professor destacou que o dataset possui uma variável target chamada "target_default" (inadimplente ou adimplente) e outra chamada "target_fraude" que não seria utilizada neste modelo.

Tópico 3: Tipos de aprendizado de máquina

O que foi abordado: Diferenciação entre aprendizado supervisionado e não supervisionado, e entre problemas de classificação e regressão.

Como o professor explicou: Explicou que o modelo é supervisionado porque alguém já fez a marcação (rotulou) dos dados, indicando quais clientes são inadimplentes e quais são adimplentes. É um problema de classificação porque a resposta é categórica (sim ou não), diferente de regressão onde o resultado seria um valor numérico contínuo.

Exemplos utilizados: Se o objetivo fosse determinar o valor do limite do cartão para cada cliente (valor escalar), seria regressão. Como o objetivo é classificar o cliente em "inadimplente" ou "adimplente", é classificação. Comparou com a evasão de alunos: usar dados de matrícula, faltas e notas para prever se o aluno pode evadir.

Observações importantes: O professor enfatizou que no aprendizado supervisionado existe uma variável target (alvo) que foi previamente rotulada por um humano, e o modelo aprende a partir desses rótulos.

Tópico 4: Análise exploratória dos dados (EDA)

O que foi abordado: Exame das dimensões do dataset, identificação de tipos de variáveis, verificação da estrutura dos dados.

Como o professor explicou: Demonstrou no Colab que o dataset tem 45.000 linhas e 43 colunas. Explicou a diferença entre variáveis numéricas (int, float) e categóricas (object/string). Mostrou os comandos `.shape`, `.head()`, `.info()`, `.dtypes` para explorar o dataset.

Exemplos utilizados: Mostrou colunas como ID do cliente (código incremental sem valor preditivo), score do cliente, tempo de emprego, renda anual, estado civil, etc. Explicou que o ID não ajuda a prever inadimplência, servindo apenas como chave primária.

Observações importantes: Ressaltou que nem todas as colunas preenchidas são necessariamente importantes para o modelo. A presença de dados completos não garante relevância para a previsão.

Tópico 5: Análise descritiva

O que foi abordado: Uso do comando `.describe()` para obter estatísticas descritivas: contagem, média, desvio padrão, valores mínimo e máximo, quartis (25%, 50%, 75%).

Como o professor explicou: Mostrou na prática o output do `describe()`, explicando cada métrica: count (quantidade de dados preenchidos), mean (média), std (desvio padrão), min/max, e os quartis. Explicou que o desvio padrão indica o quanto os dados estão espalhados em relação à média.

Exemplos utilizados: Analisou a variável "renda anual" mostrando que a média era aproximadamente 13.000, com desvio padrão de 16.000, indicando grande variabilidade nos dados. Explicou que valores muito acima da média + 2 desvios padrão são considerados outliers.

Observações importantes: O professor enfatizou a importância de entender a distribuição dos dados antes de construir qualquer modelo. A análise descritiva é fundamental para identificar padrões e anomalias.

Tópico 6: Tratamento de dados faltantes

O que foi abordado: Estratégias para lidar com dados ausentes (missing values/NaN): exclusão de linhas, imputação pela média, moda ou mediana, e uso de modelos para predição de valores faltantes.

Como o professor explicou: Apresentou três abordagens principais: (1) Excluir todas as linhas com dados faltantes; (2) Imputar pelo valor mais frequente (moda), média ou

mediana; (3) Usar o modelo de IA para aprender o padrão e preencher os dados. Explicou os riscos de cada abordagem, especialmente o viés que pode ser introduzido ao imputar dados artificialmente.

Exemplos utilizados: No dataset, havia 3.150 clientes com dados faltantes na variável target. O professor optou por excluir essas linhas em vez de imputar, explicando que o risco de viés seria alto para a variável alvo. Para variáveis com menos de 25% de dados faltantes, é possível imputar; entre 25% e 30% deve-se analisar; acima de 30% é melhor excluir a variável.

Observações importantes: Regra prática apresentada: variáveis com mais de 30% de dados ausentes devem ser removidas. Para a variável target, o professor optou por não imputar para evitar viés, preferindo perder dados a inventar informação.

Tópico 7: Análise de outliers

O que foi abordado: Conceito de outlier, métodos de identificação (desvio padrão, boxplot, IQR) e estratégias de tratamento.

Como o professor explicou: Definiu outlier como um valor que está mais de 2 desvios padrão acima ou abaixo da média. Enfatizou que outlier não é necessariamente um dado errado, mas um valor atípico que precisa ser avaliado. Mostrou técnicas de visualização usando boxplot e explicou o conceito de IQR (Interquartile Range).

Exemplos utilizados: Se a renda média dos clientes é R\$15.000 e um cliente ganha R\$1.000.000, esse cliente é um outlier. Não significa que o dado está errado, apenas que é um valor muito distante da média. Mostrou visualmente os boxplots do dataset.

Observações importantes: Nem todo outlier deve ser removido. O professor alertou que é preciso avaliar caso a caso. Para o modelo de Machine Learning, outliers podem prejudicar a performance se não forem tratados adequadamente. A regra de 2 desvios padrão é uma referência, mas pode ser ajustada conforme o contexto do negócio.

Tópico 8: Análise de correlação

O que foi abordado: Conceito de correlação entre variáveis, diferença entre correlação e causalidade, uso de mapa de calor (heatmap) para visualizar correlações.

Como o professor explicou: Explicou que a correlação mede o grau de relação linear entre duas variáveis, variando de -1 (correlação negativa perfeita) a +1 (correlação positiva perfeita). Mostrou o mapa de calor no Colab e explicou como interpretar as cores e valores. Dedicou tempo para explicar que correlação não implica causalidade.

Exemplos utilizados: Usou o exemplo clássico: aumento na venda de sorvetes se correlaciona com ataques de tubarão. Isso não significa que sorvete causa ataques de tubarão. A variável confundidora é o calor (verão), que aumenta tanto a venda de sorvetes quanto a ida às praias.

Observações importantes: O professor enfatizou que essa é uma das análises mais importantes antes de construir o modelo. Variáveis muito correlacionadas entre si podem causar multicolinearidade e prejudicar o modelo.

Tópico 9: Balanceamento de classes

O que foi abordado: O problema de datasets desbalanceados, onde uma classe tem muito mais exemplos que outra, e técnicas para lidar com isso.

Como o professor explicou: Mostrou que no dataset a proporção de adimplentes é muito maior que de inadimplentes (aproximadamente 86% adimplentes vs 14% inadimplentes). Explicou que isso pode fazer o modelo ser enviesado para a classe majoritária. Apresentou técnicas de undersample (reduzir a classe majoritária) e oversample (aumentar a classe minoritária, incluindo SMOTE).

Exemplos utilizados: Se tenho 100 exemplos de adimplentes e 10 de inadimplentes, o modelo pode simplesmente "chutar" adimplente para todos e acertar 90%, mas sem realmente aprender o padrão de inadimplência.

Observações importantes: O professor mencionou que modelos ensemble como XGBoost são mais preparados para lidar com dados desbalanceados. Recomendou que os alunos experimentem técnicas de reamostragem em seus trabalhos.

Tópico 10: Limpeza e preparação dos dados

O que foi abordado: Processo prático de limpeza do dataset: remoção de colunas irrelevantes, exclusão de dados faltantes na variável target, remoção de variáveis com alta porcentagem de nulos.

Como o professor explicou: Demonstrou no Colab a execução de cada etapa de limpeza, mostrando o antes e depois. Removeu o ID do cliente (não tem valor preditivo), a coluna target_fraude (não é o foco deste modelo), e variáveis com mais de 30% de dados faltantes. Usou o comando dropna() para remover linhas com valores nulos no target_default.

Exemplos utilizados: Mostrou como o dataset diminuiu de 45.000 para aproximadamente 41.000 linhas após a limpeza dos dados faltantes na variável target. Mostrou a verificação com .isnull().sum() para conferir dados faltantes remanescentes.

Observações importantes: O professor criou cópias do dataset antes de cada transformação (ex: df_clean) para não perder os dados originais caso algo desse errado. Essa é uma boa prática de ciência de dados.

Tópico 11: Padronização (StandardScaler)

O que foi abordado: Processo de padronização das variáveis numéricas para colocá-las na mesma escala, utilizando o StandardScaler do scikit-learn.

Como o professor explicou: Explicou que variáveis em escalas muito diferentes (ex: renda de 0 a 1.000.000 vs. idade de 18 a 80) podem prejudicar o modelo, pois algumas variáveis

teriam mais "peso" simplesmente por terem valores maiores. O StandardScaler transforma os dados para média 0 e desvio padrão 1.

Exemplos utilizados: Mostrou que antes da padronização, variáveis como renda anual tinham valores na casa dos milhares, enquanto outras tinham valores entre 0 e 1. Após a padronização, todas ficaram na mesma escala, com valores centrados em zero.

Observações importantes: O professor retirou a variável `target_default` antes da padronização porque ela só tem valores True/False e não precisa ser escalada. Criou um novo dataframe (`scale_df`) para não perder o dataset limpo original.

Tópico 12: Construção e comparação de modelos

O que foi abordado: Importação e treinamento de múltiplos modelos de Machine Learning: Árvore de Decisão (Decision Tree), Random Forest, XGBoost, KNN (K-Nearest Neighbors) e Regressão Logística. Divisão dos dados em treino e teste (`train_test_split`).

Como o professor explicou: Mostrou que com poucas linhas de código (scikit-learn) é possível importar, treinar e avaliar um modelo. Dividiu os dados em 80% treino e 20% teste. Treinou cada modelo e comparou os resultados de acurácia. Explicou que a etapa de preparação dos dados (que levou mais de 2 horas) é o que consome a maior parte do trabalho, enquanto o treinamento em si é rápido.

Exemplos utilizados: Árvore de Decisão alcançou cerca de 83% de acurácia. Random Forest (modelo ensemble) alcançou resultados superiores. Explicou que o Random Forest é como criar centenas de árvores de decisão, onde cada uma é treinada com uma amostra diferente dos dados, e o resultado final é a "votação" de todas as árvores.

Observações importantes: O professor mencionou que em aulas futuras iria explicar em detalhe o funcionamento de cada algoritmo. Enfatizou que o trabalho pesado está na preparação dos dados e que com o scikit-learn, treinar um modelo exige apenas 3-4 linhas de código.



Principais Conceitos

Dado como novo petróleo: Analogia que indica que dados brutos, assim como o petróleo, não têm valor se não forem tratados e refinados.

Análise Exploratória de Dados (EDA): Processo de investigação inicial dos dados para entender sua estrutura, distribuição, valores faltantes e relações entre variáveis.

Aprendizado Supervisionado: Tipo de Machine Learning onde o modelo aprende a partir de dados rotulados, ou seja, com respostas conhecidas (target).

Classificação vs. Regressão: Classificação prevê categorias (ex: inadimplente/adimplente); Regressão prevê valores numéricos contínuos (ex: valor do limite do cartão).

Target (Variável Alvo): A variável que o modelo deve aprender a prever. No caso, `target_default` indica se o cliente é inadimplente ou adimplente.

Dados Faltantes (Missing Values/NaN): Valores ausentes no dataset que precisam ser tratados antes da modelagem, seja por exclusão ou imputação.

Outlier: Valor atípico, muito distante da média (geralmente acima de 2 desvios padrão). Precisa ser avaliado caso a caso — não é necessariamente um erro.

Correlação: Medida da relação linear entre duas variáveis (-1 a +1). Correlação não implica causalidade.

Desbalanceamento de Classes: Quando uma classe tem muito mais exemplos que outra, podendo enviar o modelo para a classe majoritária.

StandardScaler (Padronização): Técnica que transforma as variáveis para média 0 e desvio padrão 1, colocando todas na mesma escala.

Train/Test Split: Divisão dos dados em conjunto de treino (para o modelo aprender) e teste (para avaliar a performance), geralmente 80%/20%.

Modelo Ensemble: Técnica que combina múltiplos modelos para obter uma previsão melhor. O Random Forest, por exemplo, utiliza centenas de árvores de decisão que "votam" no resultado final.

Atividades / Exercícios

O professor mencionou que compartilharia o notebook do Google Colab com os alunos para que pudessem fazer uma cópia e praticar. Sugeriu as seguintes atividades:

 **Enunciado:** Explorar o notebook compartilhado do projeto "Avaliação de Risco de Crédito" no Google Colab, reproduzir as análises feitas em aula e experimentar variações.

 **Requisitos:** Abrir o Google Colab, fazer uma cópia do notebook, executar as células, e experimentar modificações como: alterar técnicas de tratamento de dados faltantes, testar diferentes estratégias de balanceamento de classes, comparar os resultados de diferentes modelos de Machine Learning.

 **Detalhes importantes:** O professor indicou que os alunos podem "brincar" com o modelo à vontade, testando diferentes configurações. Sugeriu que observem como cada etapa de preparação impacta o resultado final do modelo. Mencionou que futuramente seriam propostas atividades formais baseadas neste projeto.

Observações Importantes

Alerta 1: O professor enfatizou repetidamente que 80% do trabalho em ciência de dados é preparação e limpeza dos dados. O modelo em si (treinamento) é a parte mais rápida.

Alerta 2: Nunca imputar valores na variável target (alvo). O professor optou por excluir linhas com target faltante para evitar viés.

Alerta 3: Correlação NÃO implica causalidade. Esse é um erro comum que deve ser evitado.

Alerta 4: O modelo precisa de manutenção contínua. Um modelo que funciona com 98% de acurácia hoje pode degradar ao longo do tempo à medida que novos perfis de clientes surgem (conceito de model drift).

Alerta 5: Dados desbalanceados são a norma em problemas reais. É essencial usar técnicas de balanceamento ou modelos ensemble para lidar com isso.

Alerta 6: Sempre criar cópias dos dados antes de transformações. Isso evita perder o dataset original em caso de erro.

Dica para prova: Entender bem a diferença entre classificação e regressão, supervisionado e não supervisionado, e o conceito de target. Também é fundamental compreender as etapas do pipeline de dados: coleta → limpeza → análise exploratória → preparação → modelagem → avaliação.



Resumo Final

A Aula 01 de Inteligência Artificial apresentou o projeto prático "Avaliação de Risco de Crédito" como caso de estudo para o curso. O professor Rogério conduziu os alunos desde a contextualização do problema (prever inadimplência de clientes) até a construção e comparação de modelos de Machine Learning, passando por todas as etapas do pipeline de ciência de dados. Foram abordados conceitos fundamentais como análise exploratória, tratamento de dados faltantes, identificação de outliers, análise de correlação (com ênfase na diferença entre correlação e causalidade), balanceamento de classes e padronização de variáveis. O professor demonstrou na prática, usando Python no Google Colab, como cada etapa é executada, sempre enfatizando que a preparação dos dados consome a maior parte do tempo e esforço de um projeto de IA. Ao final, foram treinados e comparados diversos modelos (Árvore de Decisão, Random Forest, XGBoost, KNN), demonstrando que com os dados bem preparados, o treinamento do modelo em si é relativamente simples com bibliotecas como scikit-learn.